

Un encodeur factorisé auto-supervisé (VICReg conditionnel) pour graphes d'IR LLVM

Note technique — v2, 2026-07-01. Destinée à un chercheur, pour discussion et critique. Périmètre : l'encodeur uniquement (pas de décodeur, pas d'optimiseur, pas de produit).

Positionnement honnête (lire d'abord). Le projet interne s'appelle « JEPA-ASM » — **c'est un abus de langage**. La méthode ici **n'est pas du JEPA** : il n'y a ni prédicteur latent, ni masquage, ni encodeur-cible EMA. C'est un objectif de la famille **VICReg / Barlow-Twins / Siamese** (invariance + variance + covariance), appliqué de façon **conditionnelle à deux groupages supervisés** (identité de programme, niveau -0). Les inputs sont de l'**IR LLVM** (pas de l'assembleur brut). Cette note est une **note d'application + de diagnostic**, pas une contribution méthodologique nouvelle. Les résultats intrinsèques ci-dessous ne sont **pas encore étalonnés contre des baselines** (voir §7) — le pod d'entraînement étant indisponible au moment de la rédaction.

Résumé

On apprend, **sans labels manuels** (mais avec deux groupages supervisés qui définissent les positifs), un encodeur de programmes f_θ sur des graphes **ProGraML** (Cummins et al., arXiv 2003.10536 ; paquet `pip programl`), représentation GNN-sur-IR-LLVM. L'embedding de sortie est **factorisé** en deux sous-espaces, $z = [z_{sem} \parallel z_{speed}]$, entraînés pour que : - z_{sem} soit **invariant au niveau d'optimisation** -0 (sous-espace « invariant à -O »), - z_{speed} soit **invariant au programme** (sous-espace « invariant au programme »).

(Les étiquettes « sem » / « speed » sont des raccourcis aspirationnels — voir §6.)

Deux résultats **honnêtes** méritent discussion : (i) un **gate** pré-entraînement montre que le signal d'optimisation apprenable sur des fonctions isolées est **~1 bit** (O2≈O3 pour 98.4 % des fonctions, Fig. 2) ; (ii) un **bug de normalisation VICReg** effondrait la représentation à ~3 dimensions ; corrigé, le rang effectif de z_{sem} passe à **~72/96** à données constantes (Fig. 1). Ces résultats sont un run unique (**n=1**) et **sans baseline** — à considérer comme des observations à consolider, pas des mesures établies.

1. Formalisation

Graphe programme. Un programme compilé produit un graphe orienté typé $G = (V, E, \phi)$ avec nœuds V , arêtes typées $E \subseteq V \times V \times R$, $R = \{\text{control}, \text{data}, \text{call}\}$ (les flux ProGraML), et étiquette de nœud $\phi : V \rightarrow \Sigma$ (opcode/texte). La feature de nœud est l'identifiant de vocabulaire $\text{id}(\phi(v)) \in \{0, \dots, K\}$ (0 = <unk>). On note $E_r = \{(u, v) : (u, v, r) \in E\}$.

Vues. Chaque programme P est compilé aux niveaux $\ell \in \mathcal{O} = \{-00, -01, -02, -03\}$ (clang-10 embarqué par ProGraML), donnant 4 graphes G_P^ℓ . Le niveau -0 ne sert **qu'à grouper** les vues (positifs) — c'est une **supervision faible**, pas une cible de classification.

Encodeur. $f_\theta : \mathcal{G} \rightarrow \mathbb{R}^d$, $d = d_{sem} + d_{speed}$, $f_\theta(G) = [z_{sem} \parallel z_{speed}]$.

2. Modèle (FactoredEncoder)

Tronc GNN à L couches, **une convolution par relation** (schéma R-GCN / ProGraML) :

$$h_v^{(0)} = W_{in} \text{emb}(\text{id}(\phi(v))) + \text{PE}(v), \quad h^{(l+1)} = \text{LN}\left(h^{(l)} + \text{Drop}\left(\sigma\left(\sum_{r \in R} \text{GraphConv}_r(h^{(l)}, E_r)\right)\right)\right),$$

où $\mathbf{PE}(v)$ encode le log-degré entrant/sortant par relation. Lecture (pooling) concaténant moyenne et max :

$p = [\mathbf{mean}_v h_v^{(L)} \parallel \mathbf{max}_v h_v^{(L)}] \in \mathbb{R}^{2H}$. Deux têtes MLP (avec BatchNorm) projettent : $z_{sem} = g_{sem}(p) \in \mathbb{R}^{d_{sem}}$, $z_{speed} = g_{speed}(p) \in \mathbb{R}^{d_{speed}}$. Config : $H=256$, $L=6$, $d_{sem}=96$, $d_{speed}=32$, $K=8192$, entraîné de zéro.

3. Objectif d'apprentissage (VICReg conditionnel factorisé)

Batch de B programmes $\times$ 4 vues, soit $N = 4B$ embeddings, chaque ligne i étiquetée par son programme $\mathbf{prog}(i)$ et sa classe de vitesse $\mathbf{spd}(i) = \pi(\ell_i)$ (π = regroupement de niveaux, identité par défaut).

Invariance de groupe (invariance VICReg conditionnée par une classe, moyennée sur lignes et dimensions) :

$$\mathcal{I}(Z, c) = \frac{1}{Nd} \sum_{i=1}^N \|z_i - \mu_{c(i)}\|_2^2, \quad \mu_k = \frac{1}{|c^{-1}(k)|} \sum_{i: c(i)=k} z_i.$$

Termes anti-effondrement VICReg par bloc (Bardes, Ponce & LeCun, 2022) :

$$\mathcal{V}(Z) = \frac{1}{d} \sum_j \max(0, 1 - \sqrt{\text{Var}(Z_{:,j}) + \epsilon}), \quad \mathcal{C}(Z) = \frac{1}{d} \sum_{j \neq k} \text{Cov}(Z)_{jk}^2.$$

Décorrélacion croisée (terme type Barlow-Twins, Zbontar et al. 2021, appliqué entre blocs) :

$$\mathcal{X}(z_{sem}, z_{speed}) = \frac{1}{\max(d_{sem}, d_{speed})} \sum_{j,k} \text{Cov}(z_{sem}, z_{speed})_{jk}^2.$$

Perte totale ($= \alpha \mathcal{I} + \beta \mathcal{V} + \gamma \mathcal{C}$ par bloc) :

$$\mathcal{L} = \lambda_{sem} [\alpha \mathcal{I}(z_{sem}, \mathbf{prog}) + \beta \mathcal{V}(z_{sem}) + \gamma \mathcal{C}(z_{sem})] + \lambda_{spd} [\alpha \mathcal{I}(z_{speed}, \mathbf{spd}) + \beta \mathcal{V}(z_{speed}) + \gamma \mathcal{C}(z_{speed})] + \lambda_x \mathcal{X}$$

avec $(\alpha, \beta, \gamma) = (25, 25, 1)$ (valeurs canoniques VICReg) et $\lambda_{sem} = \lambda_{spd} = \lambda_x = 1$. **Aucun composant n'est nouveau** : c'est VICReg + un terme croisé Barlow-Twins sur une architecture R-GCN/ProGraML.


Données & optim. Corpus **ExeBench** (`train_real_compilable`), ~8000 fonctions C compilées O0–O3. Vocab des text (top- K). Split anti-fuite déterministe par hash. Adam, lr 10^{-3} (cosine + warmup), 50 époques, $B = 128$ programmes/batch, un GPU (A100/B200). Éval sur pool held-out disjoint. **Run unique, une seule graine.**

4. Résultats (observations, non étalonnées)

4.1 Gate : combien de bits d'optimisation sont apprenables ?

Avant d'entraîner, on mesure si le graphe **change** entre niveaux `-0` (sinon z_{speed} est impossible). Sur 555 fonctions, signature de graphe canonique par (programme, niveau) :


paire	% graphes distincts
O0 $\neq$ O1	100 %
O1 $\neq$ O2	24.9 %
O2 $\neq$ O3	1.6 %



Lecture (Fig. 2). O0 est toujours distinct ; O1/O2 n'émerge que sur les fonctions $\gtrsim 100$ nœuds ; **O2≈O3 partout** (clang sature sur des fonctions isolées : rien à inliner, boucles trop courtes pour vectoriser). Le signal d'optimisation apprenable ici est donc essentiellement **1 bit** (O0 vs optimisé) — et *ce bit est exactement le flag -O que l'on passe soi-même* (question ouverte §6). z_{speed} est quasi 1-D (rang effectif 2.6, 1 dim pour 90 % de variance).

4.2 Désentrelacement (encodeur corrigé, test 400 programmes)

grandeur	z_{sem}	z_{speed}
cos intra-classe	0.995 (par programme)	0.561 (par niveau)
cos inter-classe	0.10	0.043
écart (gap)	0.895	0.518
silhouette sur-cible	—	+0.222 (par niveau)
silhouette hors-cible	-0.004 (par -O)	-0.907 (par programme)
rang effectif / d	72.4 / 96	2.64 / 32



⚠ Deux réserves majeures sur ces chiffres. 1. Métrique gonflée par des inputs identiques. $\cos_{intra}(z_{sem}) = 0.995$ est en partie **tautologique** : pour ~75–98 % des programmes, les graphes O1/O2/O3 sont *identiques* (§4.1), donc 3 des 4 vues sont le **même input**. La vraie invariance apprise est $O0 \leftrightarrow \text{optimisé}$; **il faut recalculer la métrique sur les seules**


paires à graphe distinct (à faire, §7). Par ailleurs pousser 4 vues d'un même programme à $\cos = 0.995$ tout en gardant $\cos_{\text{inter}} = 0.10$ est de la **discrimination d'instance** (encode *quel* programme) — pas nécessairement « ce que fait le code ». 2. **Aucune baseline.** Un encodeur **random-init** sur des inputs identiques donnerait aussi $\cos_{\text{intra}} \approx 1$, et un rang effectif élevé (les features aléatoires sont haut-rang). Ces nombres **ne distinguent pas encore apprentissage vs application déterministe** tant qu'on n'a pas les contrôles random-init + sac-d'opcodes (§7).

Projections PCA 2-D (illustration) : `figures/pca_highrank.png` (z_{sem} diffus car haut-rang ; z_{speed} = axe 00-vs-optimisé).

4.3 Un bug de normalisation VICReg (résultat de méthode)

L'invariance codée **somma** sur les dimensions au lieu de moyenner, cachant un facteur d :

$\alpha_{\text{eff}} = 25 d \approx 2400 \gg \beta = 25$. L'attraction écrasait alors les termes de variance/covariance (seuls créateurs de rang), et la représentation **s'effondrait à ~3 dimensions**. Correction **sum** → **mean** — à données et coefficients identiques :



Rang effectif de z_{sem} : **2.97 → 72.4** (Fig. 1), dims pour 90 % de variance : **2 → 48**. Ajouter des données (3000→8000 programmes) ne changeait *rien* au rang — c'était bien l'objectif, pas la donnée. (*Effet de bord : la variance restaurée force z_{speed} à s'étaler ; son écart cosinus tombe de 0.92 à 0.52.*)

Correction incomplète (à noter). Après **sum** → **mean**, $\mathcal{V}$ et $\mathcal{I}$ sont en $O(1)$, et $\mathcal{C} = \frac{1}{d} \sum_{j \neq k} \text{Cov}^2$ retrouve la normalisation **canonique** de VICReg (c'est pour cela que $\gamma = 1 \ll \alpha, \beta$). En revanche le terme croisé $\mathcal{X}$ a une normalisation **ad hoc** ($\div \max(d_{\text{sem}}, d_{\text{speed}})$ sur $d_{\text{sem}} \cdot d_{\text{speed}}$ entrées) et son poids λ_x n'est **jamais ablé** — on ne sait donc pas s'il contribue un gradient réel (sous l'échantillonneur croisé programme×niveau, $\mathcal{X} \approx 0$ dès que l'invariance tient). De plus, décorrélation croisée nulle $\neq$ indépendance (2^e ordre seulement).

5. Travaux liés (positionnement)

- **Objectif.** VICReg (Bardes, Ponce & LeCun, 2022) ; terme croisé façon **Barlow Twins** (Zbontar et al., 2021). Rien de nouveau côté perte.
- **Anti-effondrement principal.** **LeJEPA + SIGReg** (Balestriero & LeCun, arXiv 2511.08544) — poussée *prouvable* et *invariante à la dimension* vers un embedding gaussien isotrope. Le bug §4.3 est précisément la fragilité des coefficients réglés à la main que SIGReg élimine par construction ; à comparer.
- **JEPA (à ne pas confondre).** JEPA = **prédiction latente** (encodeur de contexte + prédicteur, souvent cible EMA ; lignée BYOL → I-JEPA → V-JEPA). Voir **C-JEPA** (arXiv 2410.19560, hybride VICReg+JEPA contre l'effondrement), **Graph-JEPA** (arXiv 2309.16014, JEPA sur graphes), **LLM-JEPA** (arXiv 2509.14252). Notre méthode n'en fait pas partie.
- **Représentation de code / compilateur.** **ProGraML** (Cummins et al., arXiv 2003.10536, la représentation utilisée ici), **MLGO** (Google), **LLM Compiler** (Meta), **CompilerGym** — à citer comme baselines/positionnement.
- **Discrimination d'instance.** InstDisc (Wu et al., 2018) — cadre de la métrique intra/inter.

6. Ce que la note prétend / ne prétend pas

- **Prétend** : (a) un résultat négatif honnête (gate ~ 1 bit, §4.1) qui borne toute tâche d'optimisation en aval ; (b) une étude de cas reproductible d'un piège de normalisation VICReg (§4.3) ; (c) une hygiène correcte (checkpoint publié, split anti-fuite, rang effectif $\mathbf{erank}(Z) = \exp(H(\sigma/\|\sigma\|_1))$, 24 tests).
- **Ne prétend pas** : aucune nouveauté méthodologique, aucune utilité downstream démontrée, aucune supériorité sur une baseline. Les étiquettes « sémantique / vitesse / désentrelacement sans labels » sont des raccourcis ; formulation exacte : *représentation invariante à deux groupages supervisés connus (programme, niveau -O)*.

7. Plan d'expériences (réparateurs, faisables sur checkpoints/encoder.pt)

Tous réalisables en heures-jours dès que le GPU est de nouveau joignable.

1. **Contrôles / baselines** (rend toute métrique interprétable) : encodeur **random-init** sur les mêmes métriques §4.2 ; baseline **sac-d'opcodes / nombre de nœuds** ; VICReg **non factorisé** ; borne supérieure supervisée.
2. **Métrique honnête** : recalculer $\cos_{\text{intra}}(z_{\text{sem}})$ sur paires à graphe distinct (O0 $\leftrightarrow$ optimisé) et la reporter comme chiffre principal, avec le plancher random-init.
3. **Sondes linéaires gelées** : prédire -0 depuis z_{speed} , le programme / bucket d'opcodes depuis z_{sem} , chacune contre la baseline graphe.
4. **Une lecture pertinente compilateur** : récupération plus-proche-voisin du sibling optimisé d'un graphe O0 ; ou sonde type DevMap/ProGraML.
5. **Rigueur** : ≥ 5 graines (moyenne $\pm \sigma$) sur le résultat $2.97 \rightarrow 72.4$; ablation $\lambda_x = 0$; balayage $(\alpha, \beta, \gamma)/\lambda_x$; check d'indépendance non-linéaire (MI inter-blocs ou sonde prédisant un bloc depuis l'autre).
6. **Comparaison de principe** : LeJEPA/SIGReg vs la stabilisation VICReg réglée à la main.

Reproductibilité

Code + checkpoint (checkpoints/encoder.pt + vocab.json), 24 tests unitaires (dont des garde-fous de normalisation). Détails : docs/results_gate_exebench.md , results_disentangle.md , loss_review.md , revue adversariale adversarial_research_review.md .

Références (à compléter)

VICReg — Bardes, Ponce, LeCun (2022). · Barlow Twins — Zbontar et al. (2021). · ProGraML — Cummins et al. (arXiv 2003.10536). · R-GCN — Schlichtkrull et al. (2018). · LeJEPA/SIGReg — Balestrieri & LeCun (arXiv 2511.08544). · C-JEPA (2410.19560) · Graph-JEPA (2309.16014) · LLM-JEPA (2509.14252) · InstDisc — Wu et al. (2018) · MLGO, LLM Compiler, CompilerGym.